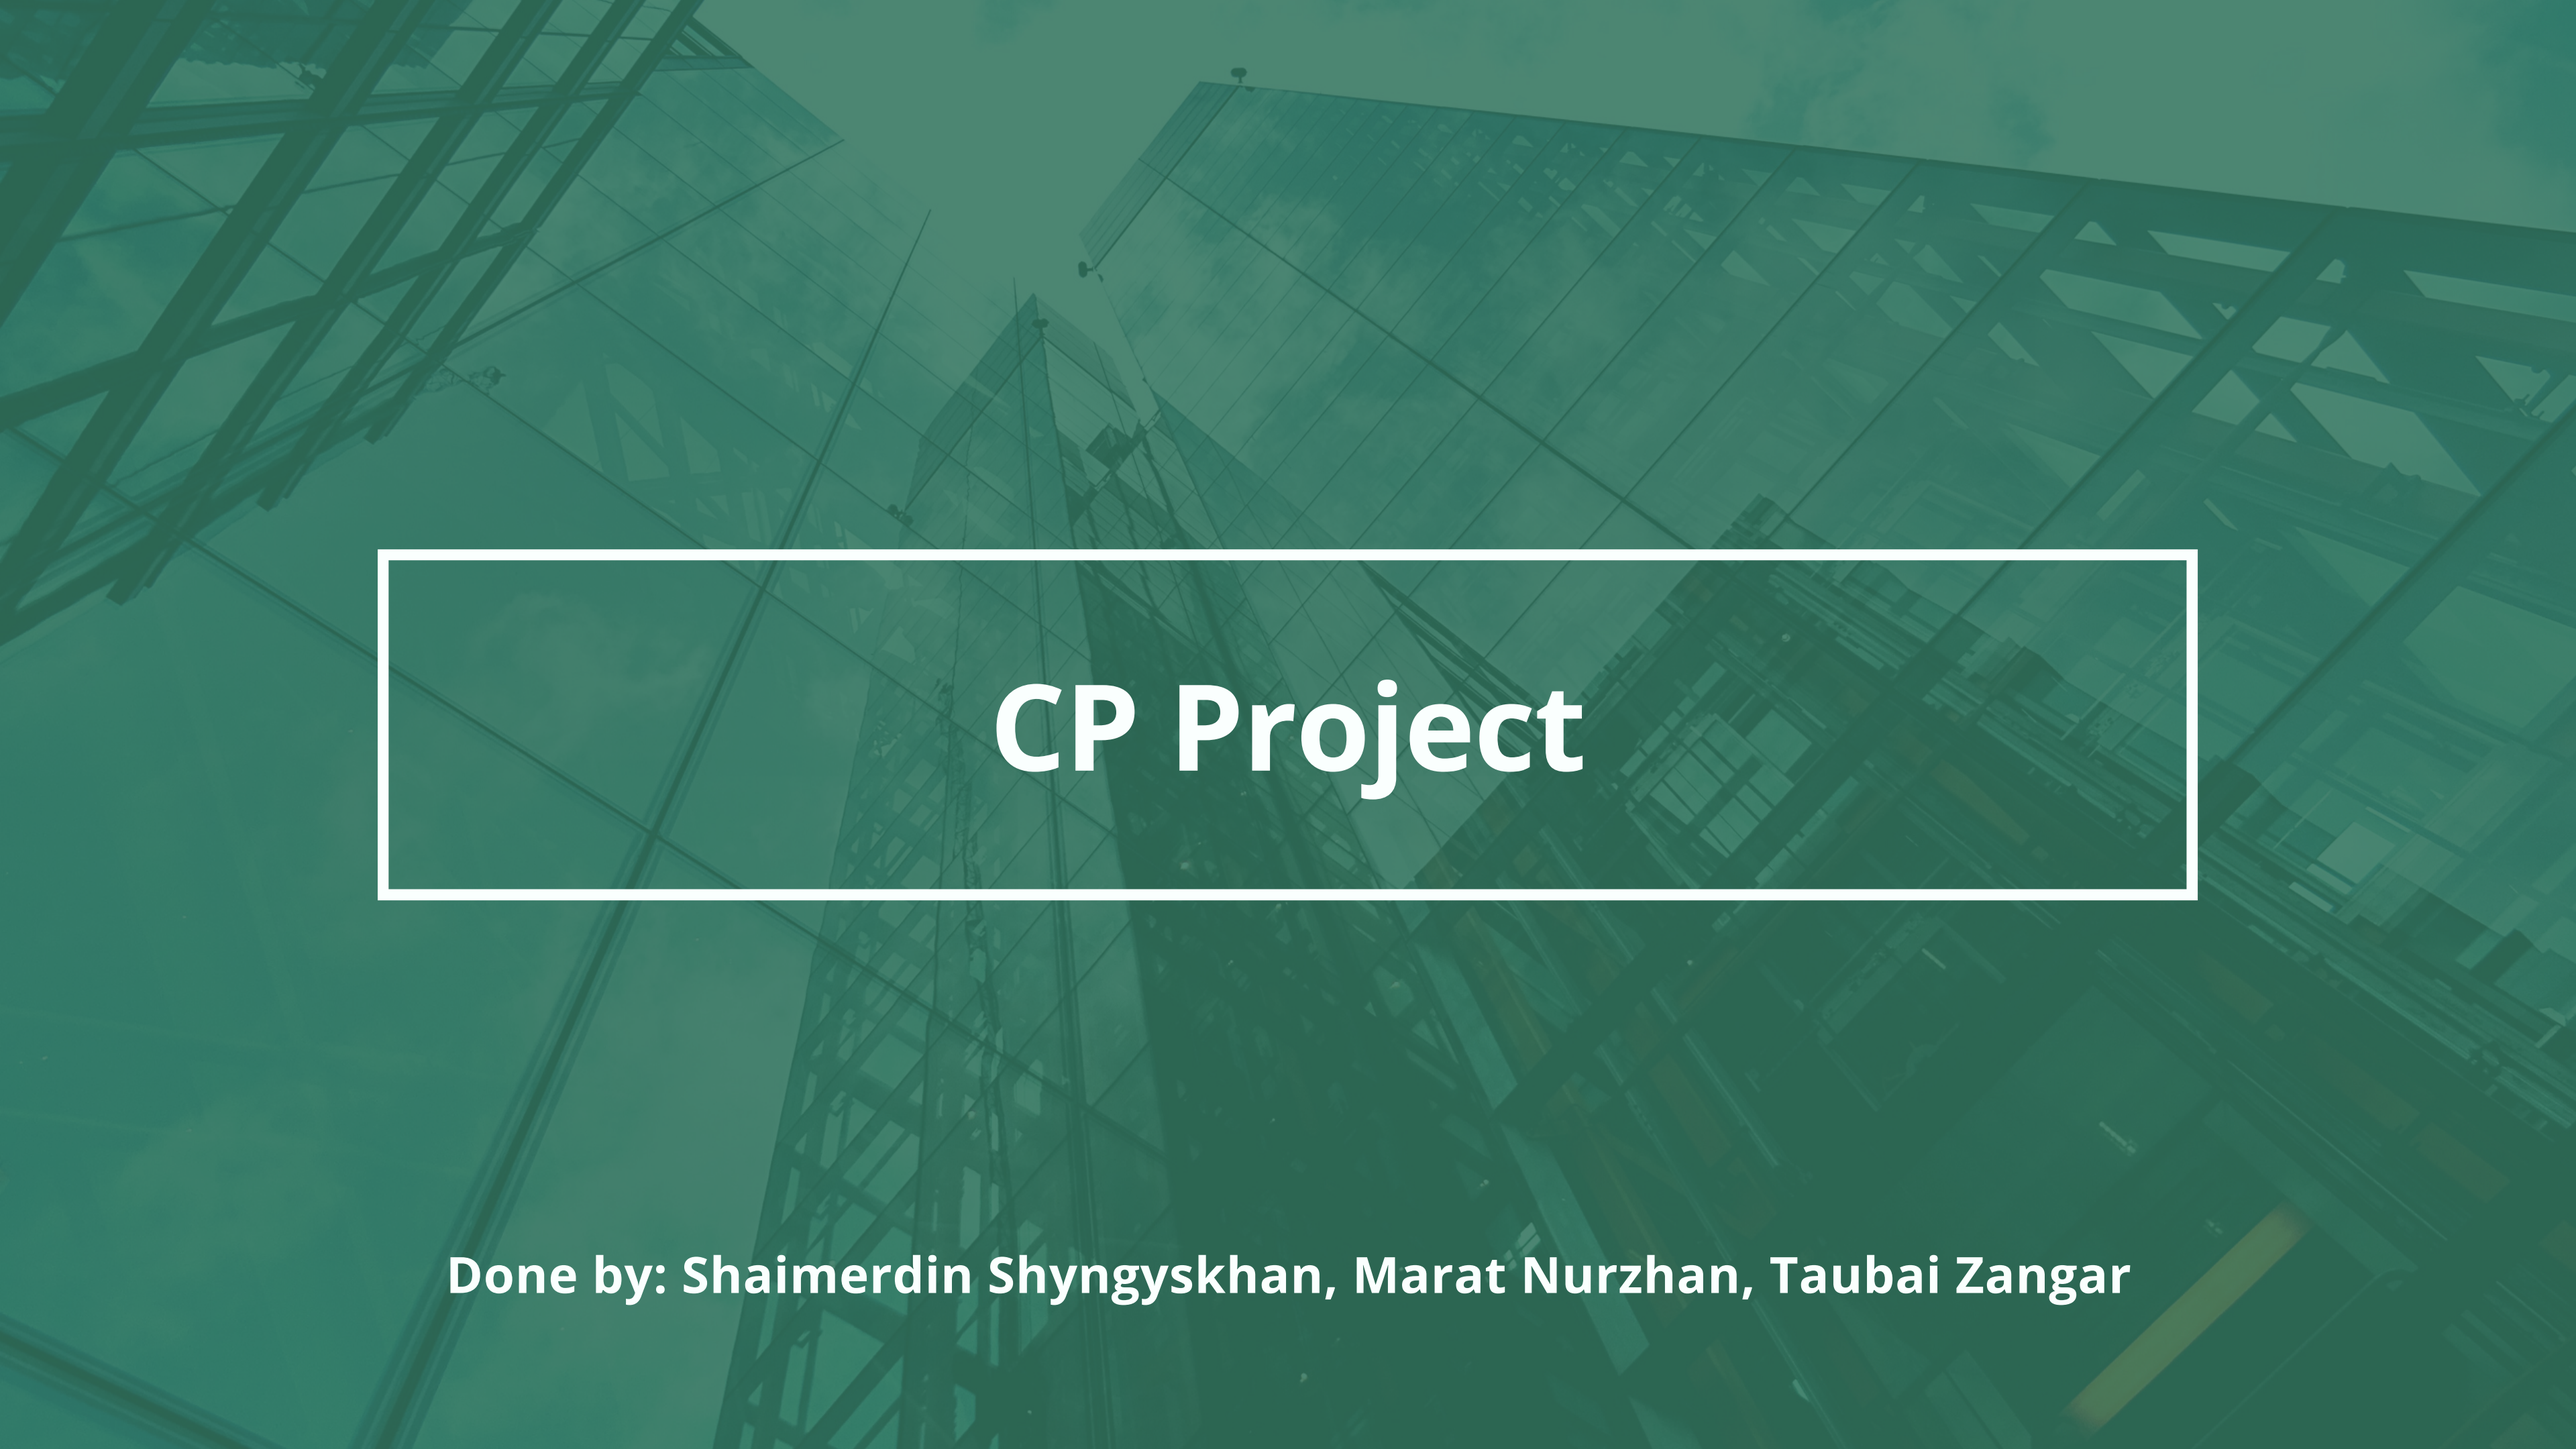

CP Project

Done by: Shaimerdin Shyngyskhan, Marat Nurzhan, Taubai Zangar

Basic overview and “pain”

*Which variables are significant in predicting the price of a car.

*How well those variables describe the price of a car.

*Significant increase for car price in the Kazakhstan's market, may put people in difficult situation in terms of when and for what type of car there would be a decent price.

Source for the dataset

1) SCRAPING
2) PARSING
3) WE USED OCTOPARSE

КОЛЁСА

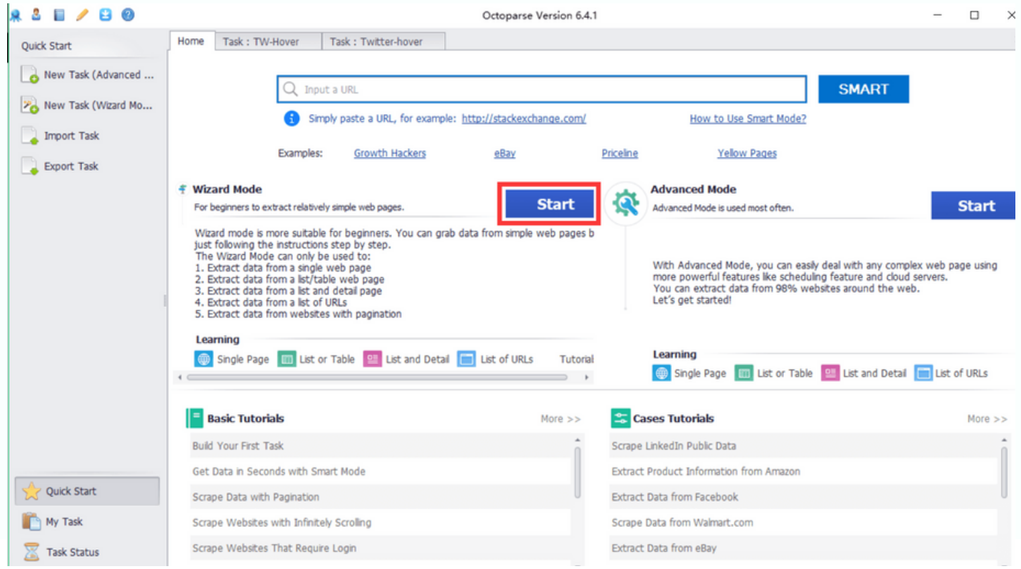

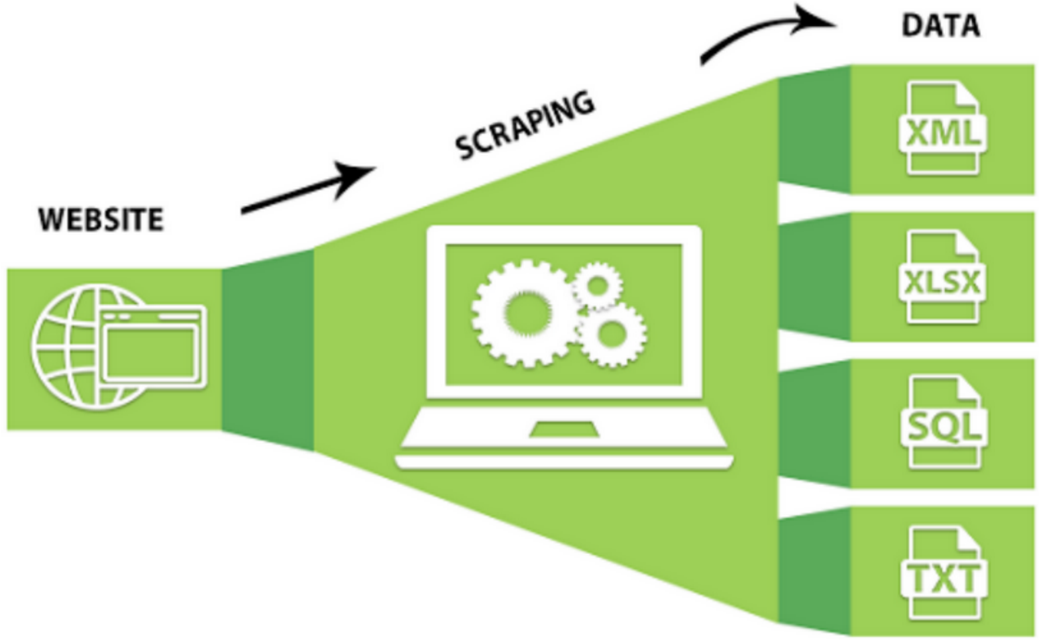

Parameters, according to which we will attempt to do a prediction

- Fuel type
- Price
- Gearbox type
- Body type
- Mileage
- Color
- Engine size
- City
- Mark
- Model

Где искать Алматы Нур-Султан (Астана) Шымкент Актобе Караганда Тараз ещё

Марка ВАЗ (Lada) Toyota Mercedes-Benz Volkswagen Nissan Audi ещё

Модель Camry Land Cruiser Prado Land Cruiser Corolla RAV 4 Highlander ещё

Все | Новая | С пробегом

☐ С фото ☐ Растаможен ☐ Аварийная/Не на ходу

Расширенный поиск

Страна происхождения ... | Кузов | Двигатель

КПП | Расположение руля | Привод

Пробег не более, км

Наличие: В наличии | На заказ

Объем двигателя, л: от | до

Цвет

Не важно

☐ металлик

Parsing process

Divided by fields and created a normal database

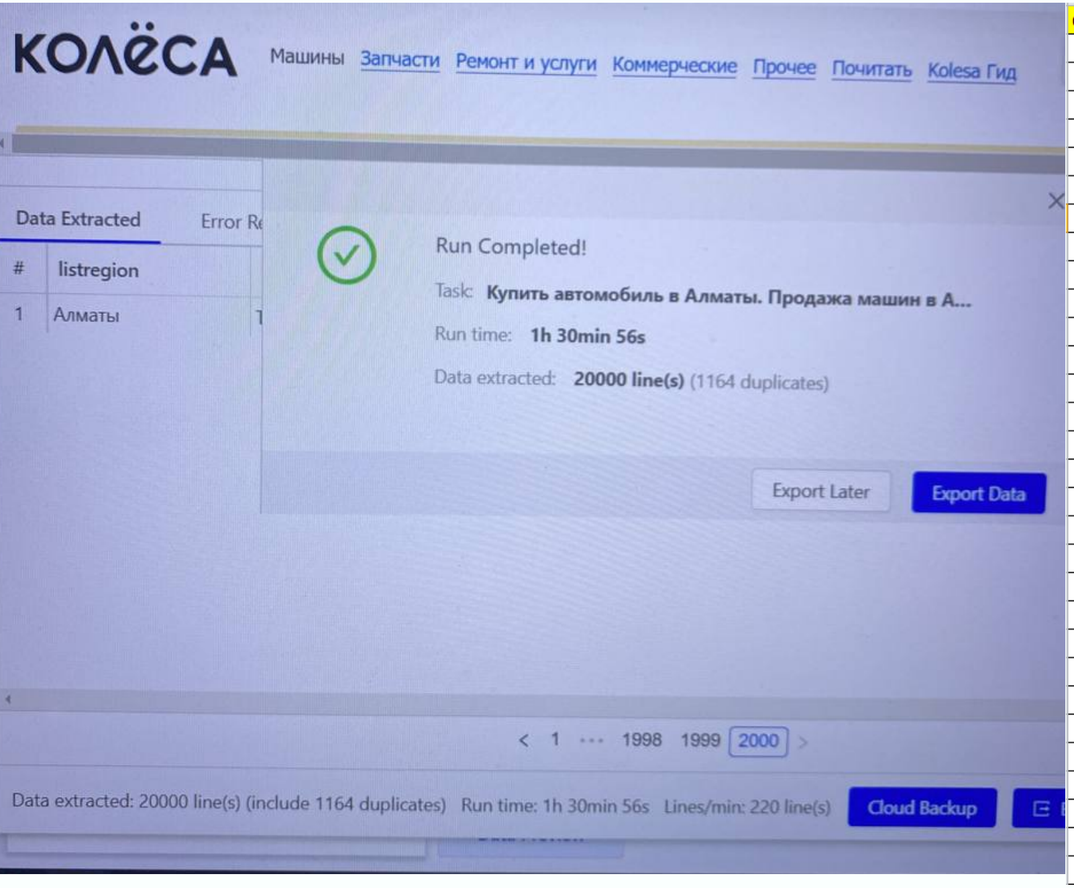

Car_id	City	Mark	Model	Price	Year	Body	EngineSize	FuelType	earboxTyp	Mileage	Color
1	Алматы	Toyota	Avensis	4200000	2003	седан	2	бензин	автомат	200000	серебристый
3	Алматы	Mitsubishi	Delica	12500000	2006	микроавт	3	бензин	автомат	180000	серебристый
4	Алматы	Infiniti	QX80	28050000	2018	внедорож	5,6	бензин	автомат	22000	белый
6	Алматы	Nissan	Patrol	11500000	2012	внедорож	5,6	бензин	автомат	105000	белый
8	Алматы	ВАЗ	(Lada)Larg	4800000	2019	минивэн	1,6	бензин	механика	90000	черный
10	Алматы	Volkswage	Golf	1750000	1995	хэтчбек	2	бензин	механика	120000	синий
11	Алматы	Toyota	Corolla	3700000	2012	седан	1,4	бензин	механика	90000	серебристый
12	Алматы	Toyota	LandCruise	9150000	2007	внедорож	2,7	газ-бензи	автомат	196000	черный
13	Алматы	Mercedes-	GLCCoupe	26500000	2019	кроссовер	2	бензин	автомат	4000	синий
17	Алматы	Toyota	Venza	8900000	2010	кроссовер	2,7	бензин	автомат	146000	серый
18	Алматы	ВАЗ	(Lada)219(	3200000	2015	седан	1,6	бензин	механика	18000	серебристый
22	Алматы	Toyota	LandCruise	17500000	2008	внедорож	4	бензин	автомат	118000	серый
26	Алматы	Hyundai	Accent	4000000	2012	седан	1,4	бензин	автомат	107000	черный
27	Алматы	Toyota	LandCruise	23500000	2013	внедорож	4,6	бензин	автомат	75000	белый
28	Алматы	Toyota	Camry	10100000	2015	седан	2	бензин	автомат	41000	белый
30	Алматы	Toyota	Camry	12200000	2017	седан	2,5	бензин	автомат	58000	белый
32	Алматы	Porsche	Panamera	65000000	2017	лифтбек	4	бензин	робот	12000	черный
34	Алматы	Infiniti	FX37	11000000	2012	кроссовер	3,7	бензин	автомат	145000	белый
36	Алматы	Toyota	Camry	12600000	2018	седан	2,5	бензин	автомат	51089	серебристый
39	Алматы	Toyota	LandCruise	16800000	2011	внедорож	4,7	бензин	типтроник	171000	белый
42	Алматы	Land	RoverRang	13300000	2014	кроссовер	2	бензин	автомат	38700	белый
48	Алматы	Kia	Rio	3600000	2012	хэтчбек	1,6	бензин	механика	175000	серый
50	Алматы	Lexus	LX570	38900000	2016	внедорож	5,7	бензин	типтроник	33000	белый
52	Алматы	Foton	Alpha	1000000	2005	фургон	2,2	дизель	механика	11111	белый
53	Алматы	Mazda	MPV	3800000	2004	минивэн	3	бензин	автомат	240000	серый
56	Алматы	Chevrolet	Spark	3950000	2018	хэтчбек	1	бензин	автомат	34000	белый
59	Алматы	Lexus	GS300	6000000	2007	седан	3	бензин	автомат	180000	черный
60	Алматы	Toyota	LandCruise	7400000	2004	внедорож	4,7	газ-бензи	автомат	346000	серебристый
61	Алматы	Hyundai	Accent	6000000	2019	седан	1,6	бензин	типтроник	42000	серебристый
64	Алматы	Toyota	LandCruise	9200000	2007	внедорож	2,7	бензин	автомат	235000	серебристый

Car Mark Frequency

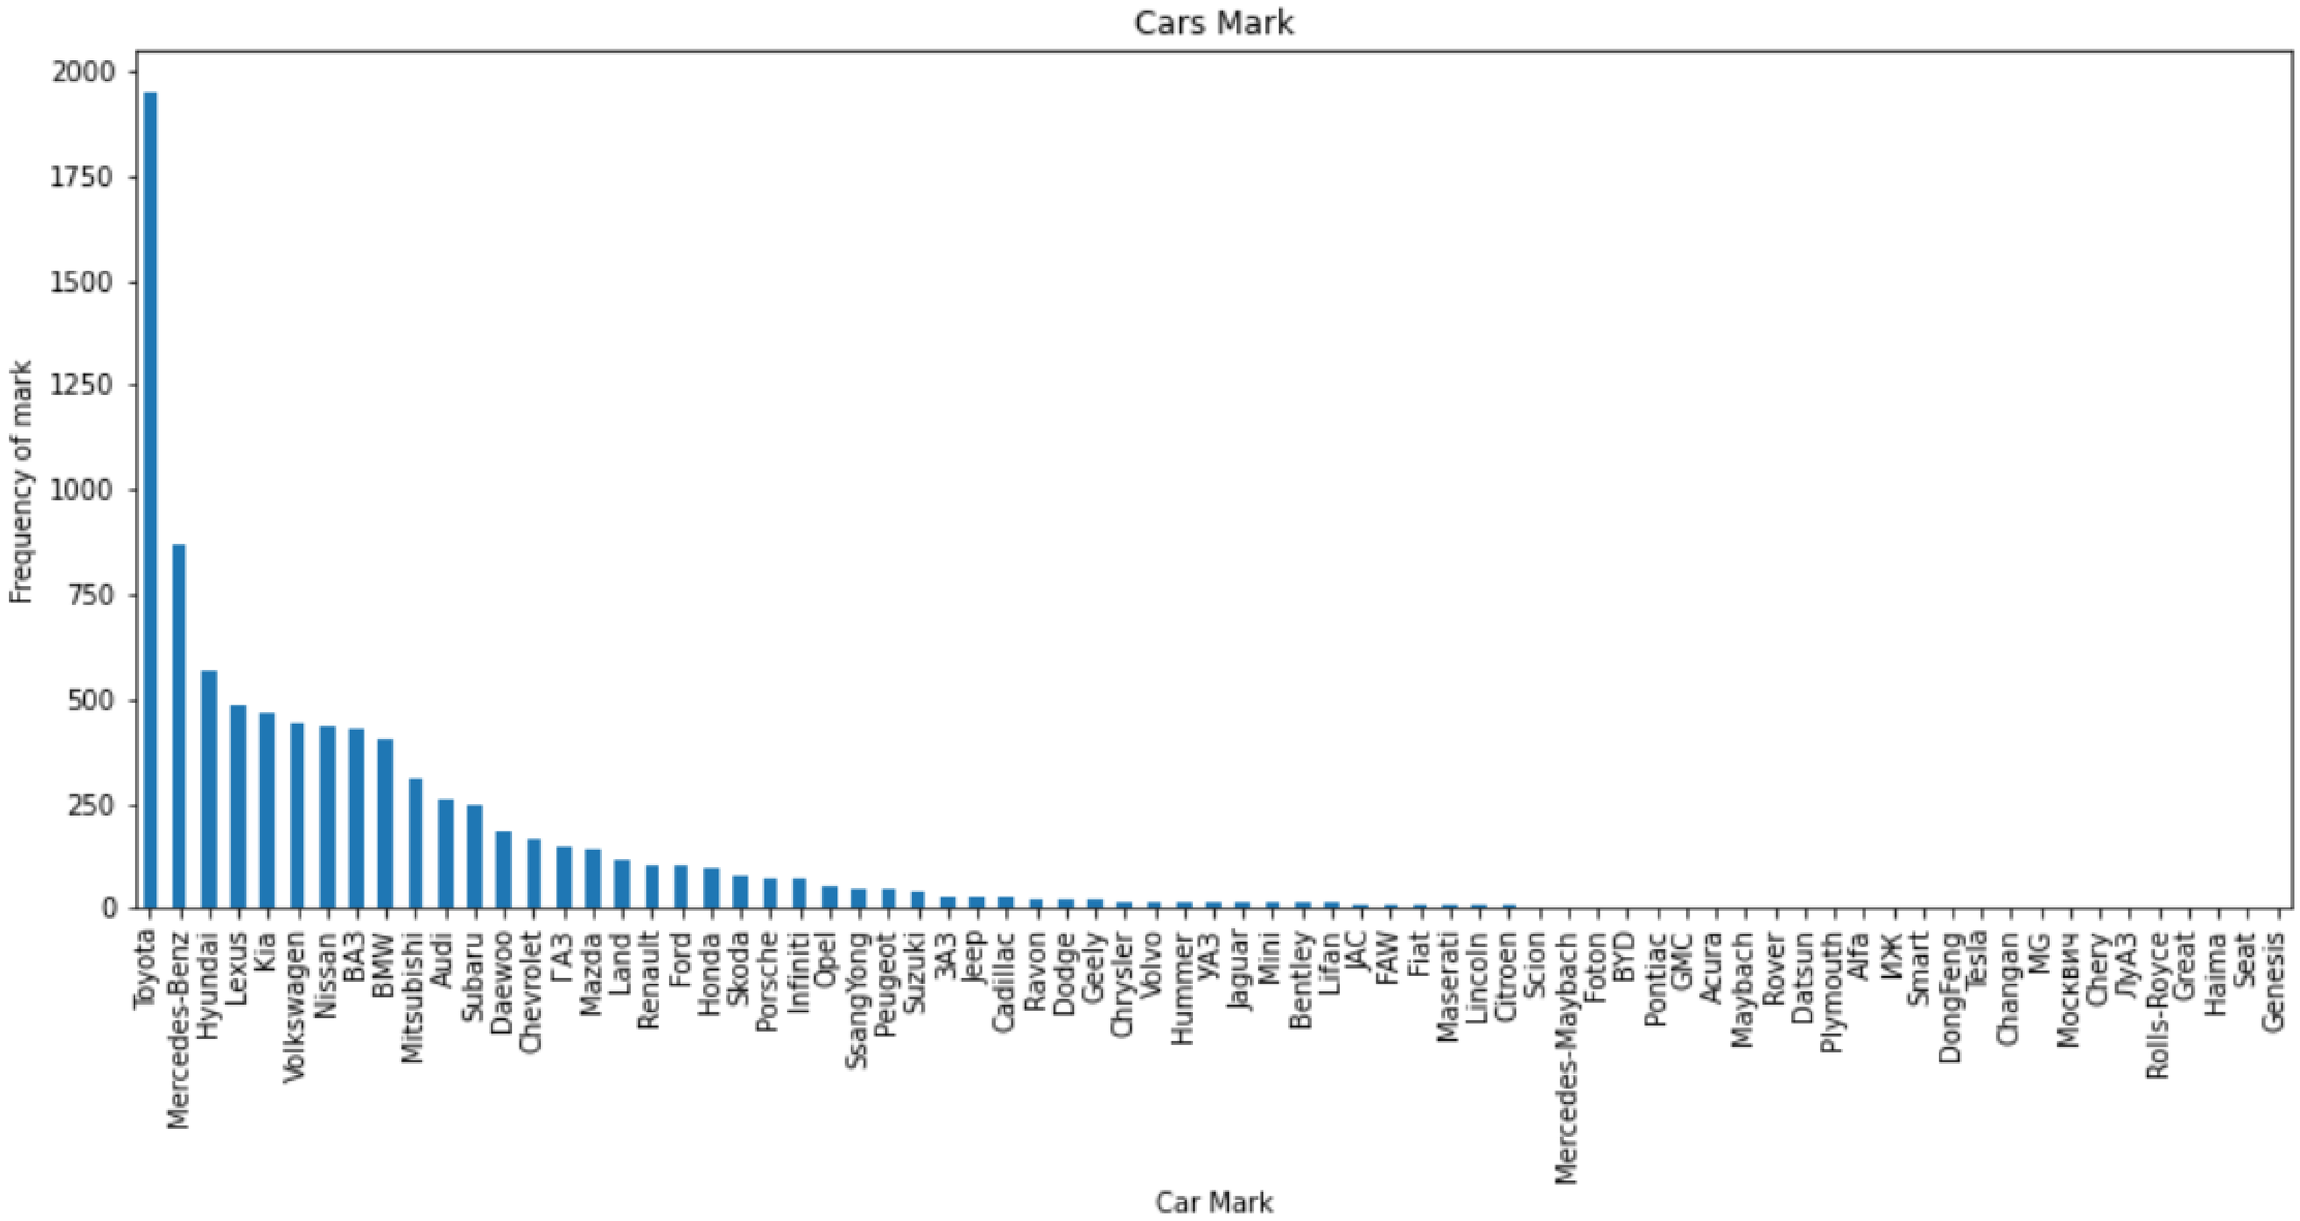

Fuel Type/Car Type Histogram

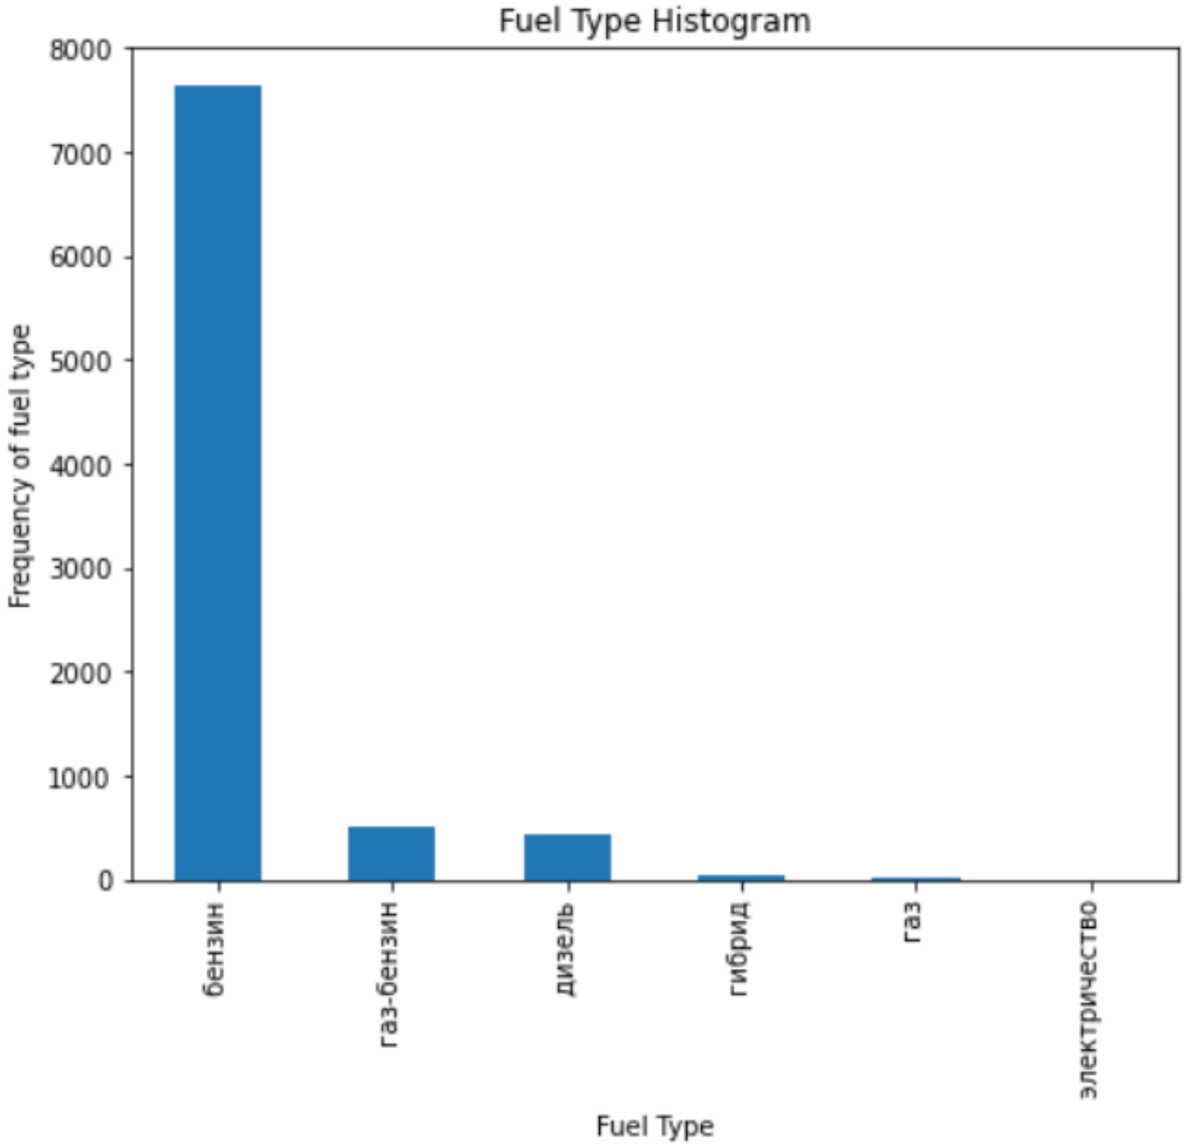

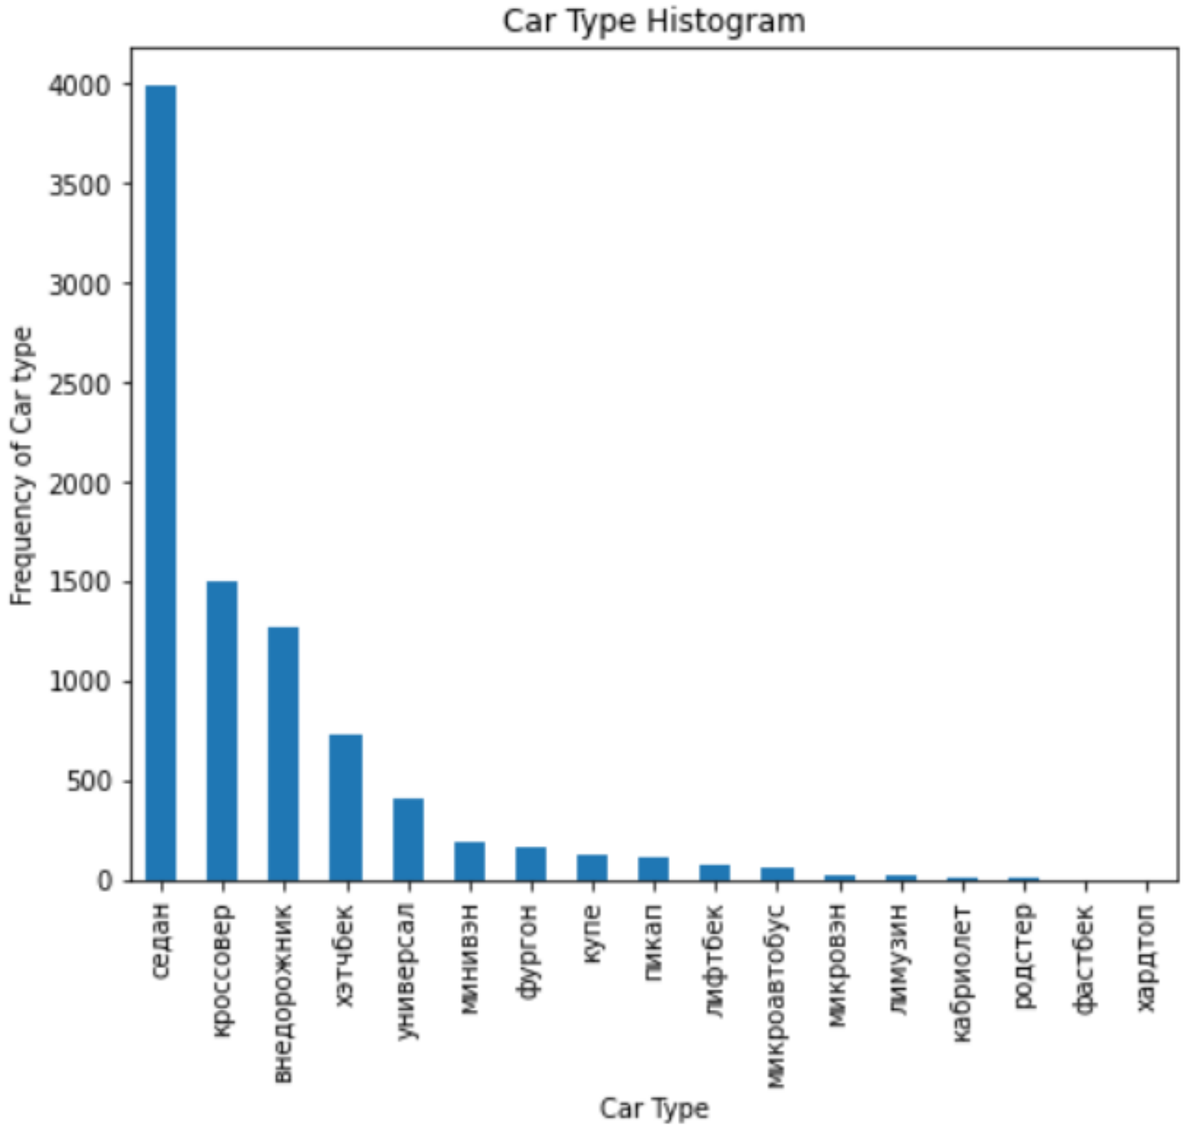

Heatmap

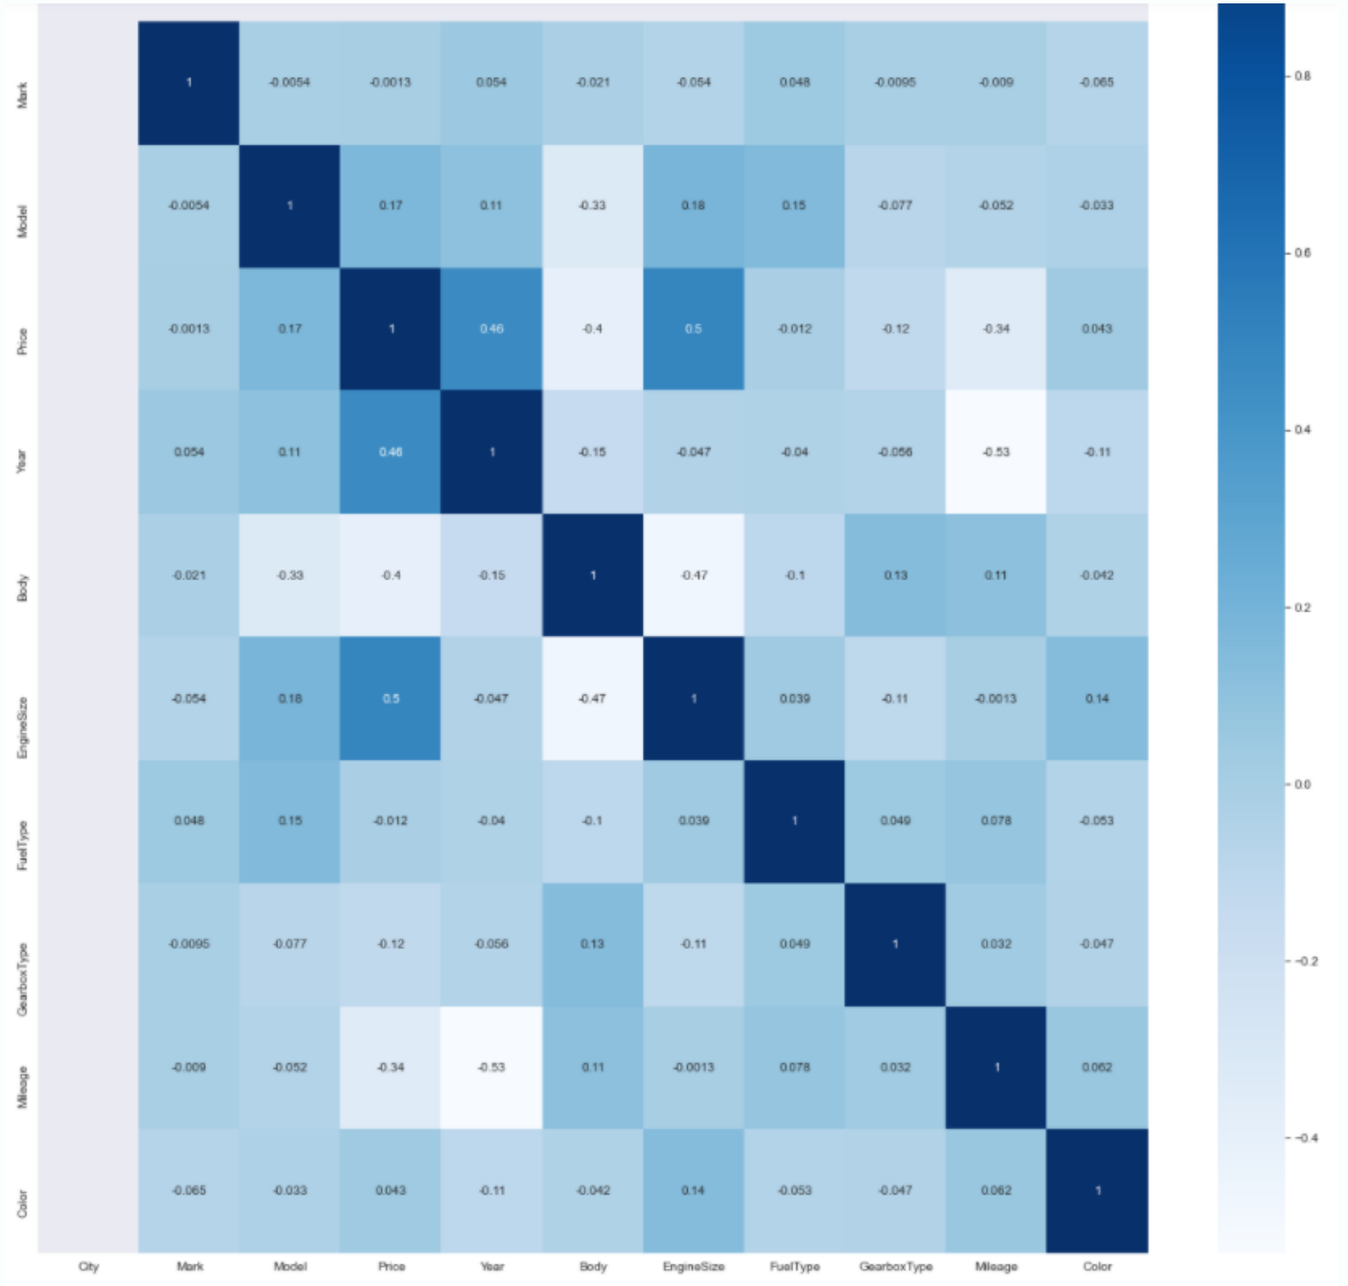
Mark
Model
Price
Year
Body
EngineSize
FuelType
GearboxType
Mileage
Color
City
1 -0.0054 -0.0013 0.054 -0.021 -0.054 0.048 -0.0095 -0.009 -0.065
-0.0054 1 0.17 0.11 -0.33 0.18 0.15 -0.077 -0.052 -0.033
-0.0013 0.17 1 0.46 -0.4 0.5 -0.012 -0.12 -0.34 0.043
0.054 0.11 0.46 1 -0.15 -0.047 -0.04 -0.056 -0.53 -0.11
-0.021 -0.33 -0.4 -0.15 1 -0.47 -0.1 0.13 0.11 -0.042
-0.054 0.18 0.5 -0.047 -0.47 1 0.039 -0.11 -0.0013 0.14
0.048 0.15 -0.012 -0.04 -0.1 0.039 1 0.049 0.078 -0.053
-0.0095 -0.077 -0.12 -0.056 0.13 -0.11 0.049 1 0.032 -0.047
-0.009 -0.052 -0.34 -0.53 0.11 -0.0013 0.078 0.032 1 0.062
-0.065 -0.033 0.043 -0.11 -0.042 0.14 -0.053 -0.047 0.062 1
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4

Algorithms

Random Forest
Linear Regression
Ridge Regression

Lasso
KNN
XGBoost

Random Forest

```
from sklearn.ensemble import RandomForestRegressor
regressor = RandomForestRegressor(n_estimators = 10, random_state = 0)
regressor.fit(X_train, y_train)
```

```
RandomForestRegressor(n_estimators=10, random_state=0)
```

```
y_pred=regressor.predict(X_test)
```

```
from sklearn.metrics import r2_score
r2_score(y_test, y_pred)
```

```
0.8315636060029487
```

Accuracy: 83.16%

Linear regression

```
from sklearn.linear_model import LinearRegression
lr = LinearRegression()

# Training Model
lr.fit(X_train,y_train)

# Model Summary
y_pred_lr = lr.predict(X_test)

r_squared = r2_score(y_test,y_pred_lr)
rmse = np.sqrt(mean_squared_error(y_test,y_pred_lr))
print("R_squared :",r_squared)
print("RMSE :",rmse)
```

```
R_squared : 0.5567774964386283
RMSE : 5142146.302533223
```

Accuracy 55.68%

Ridge regression

```
from sklearn.linear_model import Ridge

rdg=Ridge(alpha=1.0)
rdg.fit(X_train,y_train)

y_pred_rdg=rdg.predict(X_test)

r_squared = r2_score(y_test,y_pred_rdg)
rmse = np.sqrt(mean_squared_error(y_test,y_pred_rdg))
print("R_squared :",r_squared)
print("RMSE :",rmse)
```

```
R_squared : 0.5567716056233141
RMSE : 5142180.474234
```

Accuracy 55%

Lasso

```
In [39]: from sklearn.linear_model import Lasso
         from sklearn.metrics import mean_squared_error

         lso = Lasso(alpha=1.0)
         lso.fit(X_train, y_train)
         y_pred_lso = lso.predict(X_test)
```

```
In [40]: from sklearn.metrics import r2_score
         r2_score(y_test, y_pred_lso)

Out[40]: 0.5567774786106191
```

Accuracy 55%

KNN

In [32]:
```
from sklearn.neighbors import KNeighborsRegressor

knn=KNeighborsRegressor(n_neighbors=7)
knn.fit(X_train, y_train)
y_pred_knn=knn.predict(X_test)
```

In [33]:
```
from sklearn.metrics import r2_score
r2_score(y_test, y_pred_knn)
```

Out[33]:
```
0.24200554077381542
```

Accuracy 24.2%

XGBoost

In [24]:
```
from xgboost import XGBRegressor

xgb = XGBRegressor(n_estimators=1000, learning_rate=0.1)
xgb.fit(X_train, y_train, early_stopping_rounds=5, eval_set=[(X_test, y_test)], verbose=False)
y_pred_xgb = xgb.predict(X_test)
```

In [25]:
```
from sklearn.metrics import r2_score
r2_score(y_test, y_pred_xgb)
```

Out[25]:
```
0.9031754676787723
```

Accuracy 90.3%

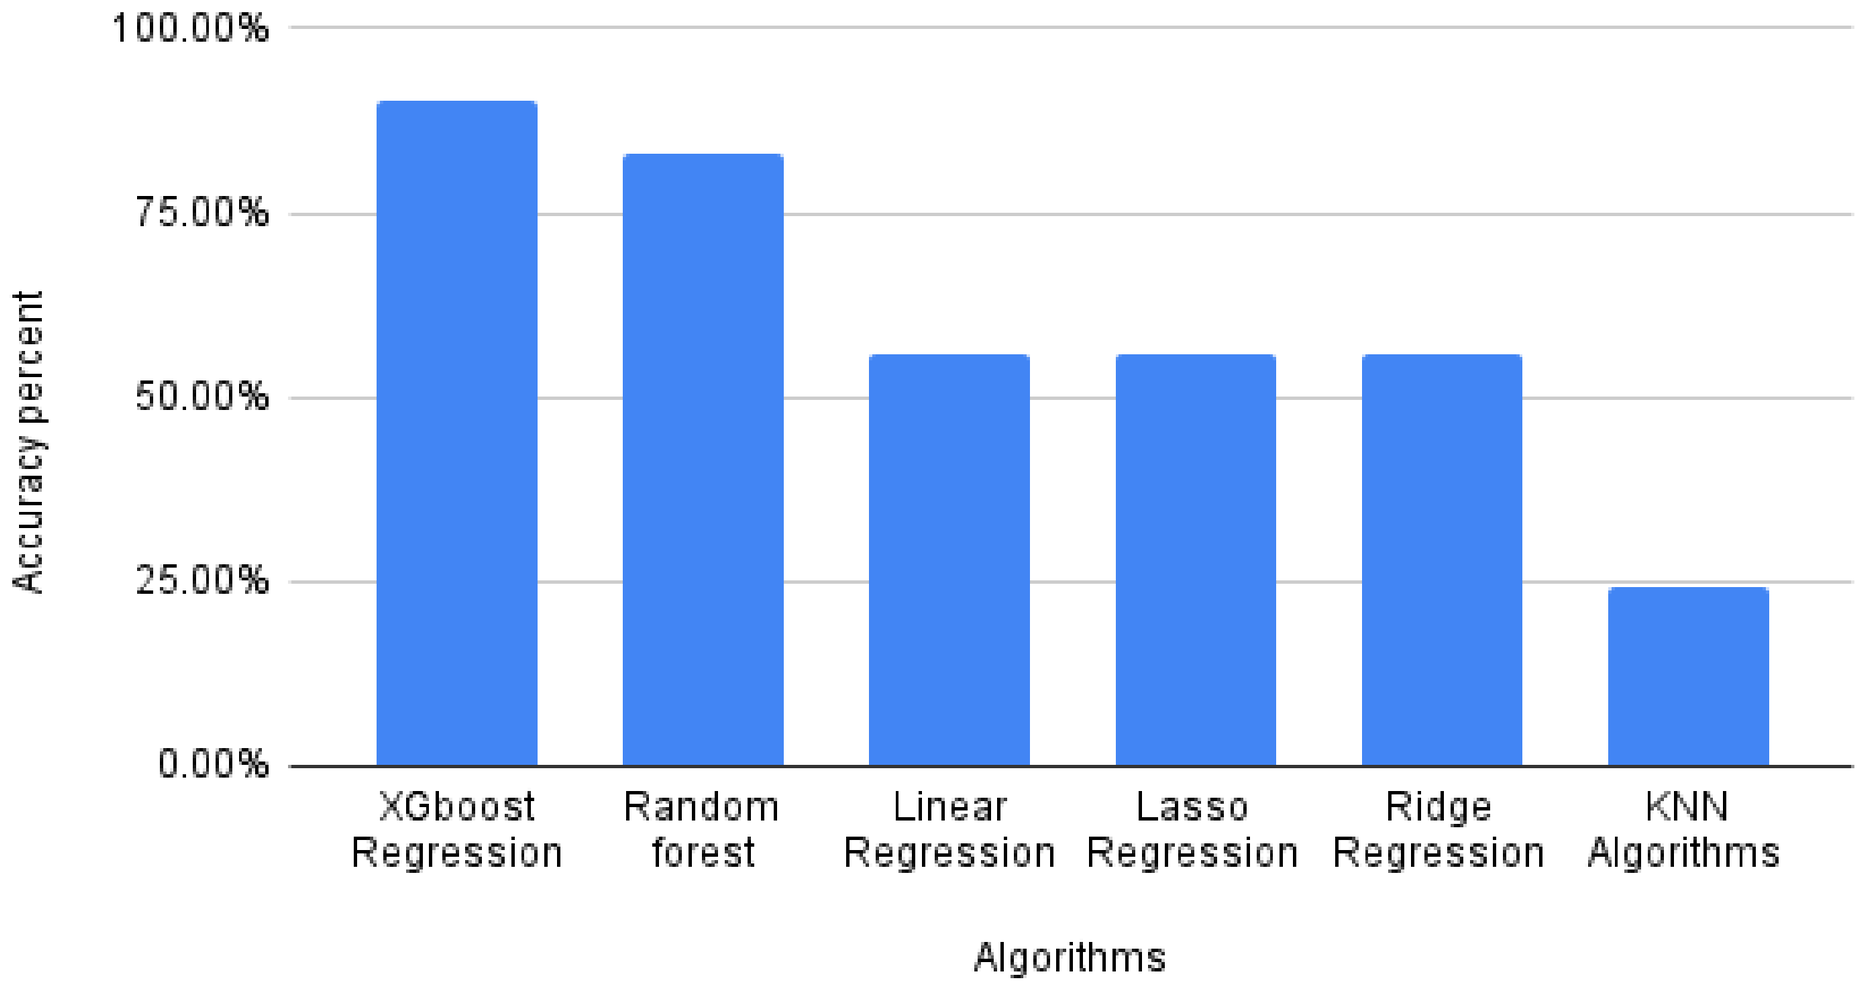
Accuracy percent относительно параметра "Algorithms"
100.00%
75.00%
50.00%
25.00%
0.00%
Accuracy percent
XGboost Regression
Random forest
Linear Regression
Lasso Regression
Ridge Regression
KNN Algorithms
Algorithms

Analyzing Abnormal Data

Normal Data RF

In [4]:
```
value = 0.13
```

In [5]:
```
Random_forest_data_normal = Random_forest_data.query("predictions < actual_price + (@value*actual_price) & \
                                                      predictions > actual_price - (@value*actual_price)")
Random_forest_data_normal
```

Out[5]:

	car_id	Mark	Model	Year	EngineSize	FuelType	Body	GearboxType	Mileage	Color	actual_price	predictions
2	5268	Volkswagen	Golf	1997	1.8	бензин	хэтчбек	механика	240000	синий	1700000	1835000.0
3	7910	Subaru	Tribeca	2007	3.6	бензин	кроссовер	автомат	265983	белый	5250000	5839000.0
4	3182	Daewoo	Nexia	2013	1.5	бензин	седан	механика	190000	белый	1640000	1760000.0
7	3236	Nissan	Qashqai	2007	2.0	бензин	кроссовер	вариатор	240550	коричневый	4620000	4565000.0
8	5989	Volkswagen	Passat	1992	1.8	бензин	универсал	механика	290000	бордовый	1550000	1395400.5
...	...	...	...	...	...	...	...	...	...	...	...	...
1726	3796	Toyota	Land\tCruiser	2012	4.6	бензин	внедорожник	автомат	145000	черный	20800000	21515000.0
1727	3847	BMW	318	2002	1.9	бензин	купе	механика	350350	серебристый	2800000	2699000.0
1728	8630	ГАЗ	ГАЗель\tNEXT	2018	2.7	бензин	фургон	механика	120000	белый	8499999	8044700.0
1729	5003	Toyota	Land\tCruiser	2008	4.7	газ-бензин	внедорожник	автомат	263000	белый	14600000	13250000.0
1730	4902	Nissan	Patrol	2013	5.6	бензин	внедорожник	автомат	222128	черный	12820000	13095000.0

948 rows × 12 columns

Abnormal Data RF

In [6]:
```
Random_forest_data_notnormal = Random_forest_data.query("predictions > actual_price + (@value*actual_price) | \
                                                         predictions < actual_price - (@value*actual_price)")
Random_forest_data_notnormal
```

Out[6]:

	car_id	Mark	Model	Year	EngineSize	FuelType	Body	GearboxType	Mileage	Color	actual_price	predictions
0	2527	Land	Rover\tFreelander	2014	2.0	бензин	кроссовер	автомат	59000	синий	9700000	13990000.0
1	6141	Toyota	Corolla	2011	1.6	бензин	седан	автомат	137500	белый	5400000	6225000.0
5	3285	Porsche	Cayenne	2008	4.8	бензин	кроссовер	типтроник	109000	голубой	7600000	9310000.0
6	8576	Toyota	HiAce	2012	2.7	бензин	микроавтобус	механика	226000	серебристый	8900000	10178998.0
9	1696	Hyundai	Coupe	2004	2.0	бензин	купе	автомат	155000	красный	2900000	3335000.0
...	...	...	...	...	...	...	...	...	...	...	...	...
1719	8181	Toyota	Land\tCruiser	2015	4.6	бензин	внедорожник	автомат	49700	белый	32500000	24590000.0
1720	3133	ВАЗ	(Lada)\t2121\tНива	2004	1.7	бензин	внедорожник	механика	170000	белый	1700000	1069555.3
1723	8545	Mitsubishi	Galant	2005	2.4	бензин	седан	автомат	429655	серый	2500000	4304000.0
1724	526	Volkswagen	Transporter	2007	2.5	дизель	минивэн	механика	173000	белый	8000000	5549000.0
1731	313	Kia	Cerato\tKoup	2012	2.0	бензин	купе	типтроник	100000	серебристый	4900000	5550000.0

782 rows × 12 columns

Algorithms	Normal	Abnormal
XGboost Regression	944	788
Random forest	948	782
Linear Regression	387	1345
Lasso Regression	387	1345
Ridge Regression	387	1345
KNN Algorithms	256	1476

Intersections of abnormal values between all models

	car_id	Mark	Model	Year	EngineSize	FuelType	Body	GearboxType	Mileage	Color	actual_price	predictions
5	3285	Porsche	Cayenne	2008	4.8	бензин	кроссовер	типтроник	109000	голубой	7600000	8628735.00
12	4285	Mercedes-Benz	S\t450	2006	4.5	бензин	седан	автомат	293196	серебристый	7000000	5823991.50
16	7084	BMW	X6	2012	4.4	бензин	кроссовер	типтроник	76000	черный	10500000	16097132.00
18	5071	Hyundai	Grandeur	2016	3.0	бензин	седан	автомат	82000	серебристый	10000000	17663204.00
21	4718	ВАЗ	(Lada)\t2121\tНива	2013	1.7	бензин	внедорожник	механика	45896	белый	2450000	3134271.25
...	...	...	...	...	...	...	...	...	...	...	...	...
1708	1974	Audi	80	1990	2.0	бензин	седан	механика	380000	красный	1380000	1041968.50
1717	4230	Kia	Cee'd	2013	1.6	бензин	хэтчбек	типтроник	253000	коричневый	5144000	4256721.00
1719	8181	Toyota	Land\tCruiser	2015	4.6	бензин	внедорожник	автомат	49700	белый	32500000	26162330.00
1724	526	Volkswagen	Transporter	2007	2.5	дизель	минивэн	механика	173000	белый	8000000	4772302.00
1731	313	Kia	Cerato\tKoup	2012	2.0	бензин	купе	типтроник	100000	серебристый	4900000	6880113.50

420 rows × 12 columns

```
Intersection: 420
```

Car frequency in abnormal dataframe

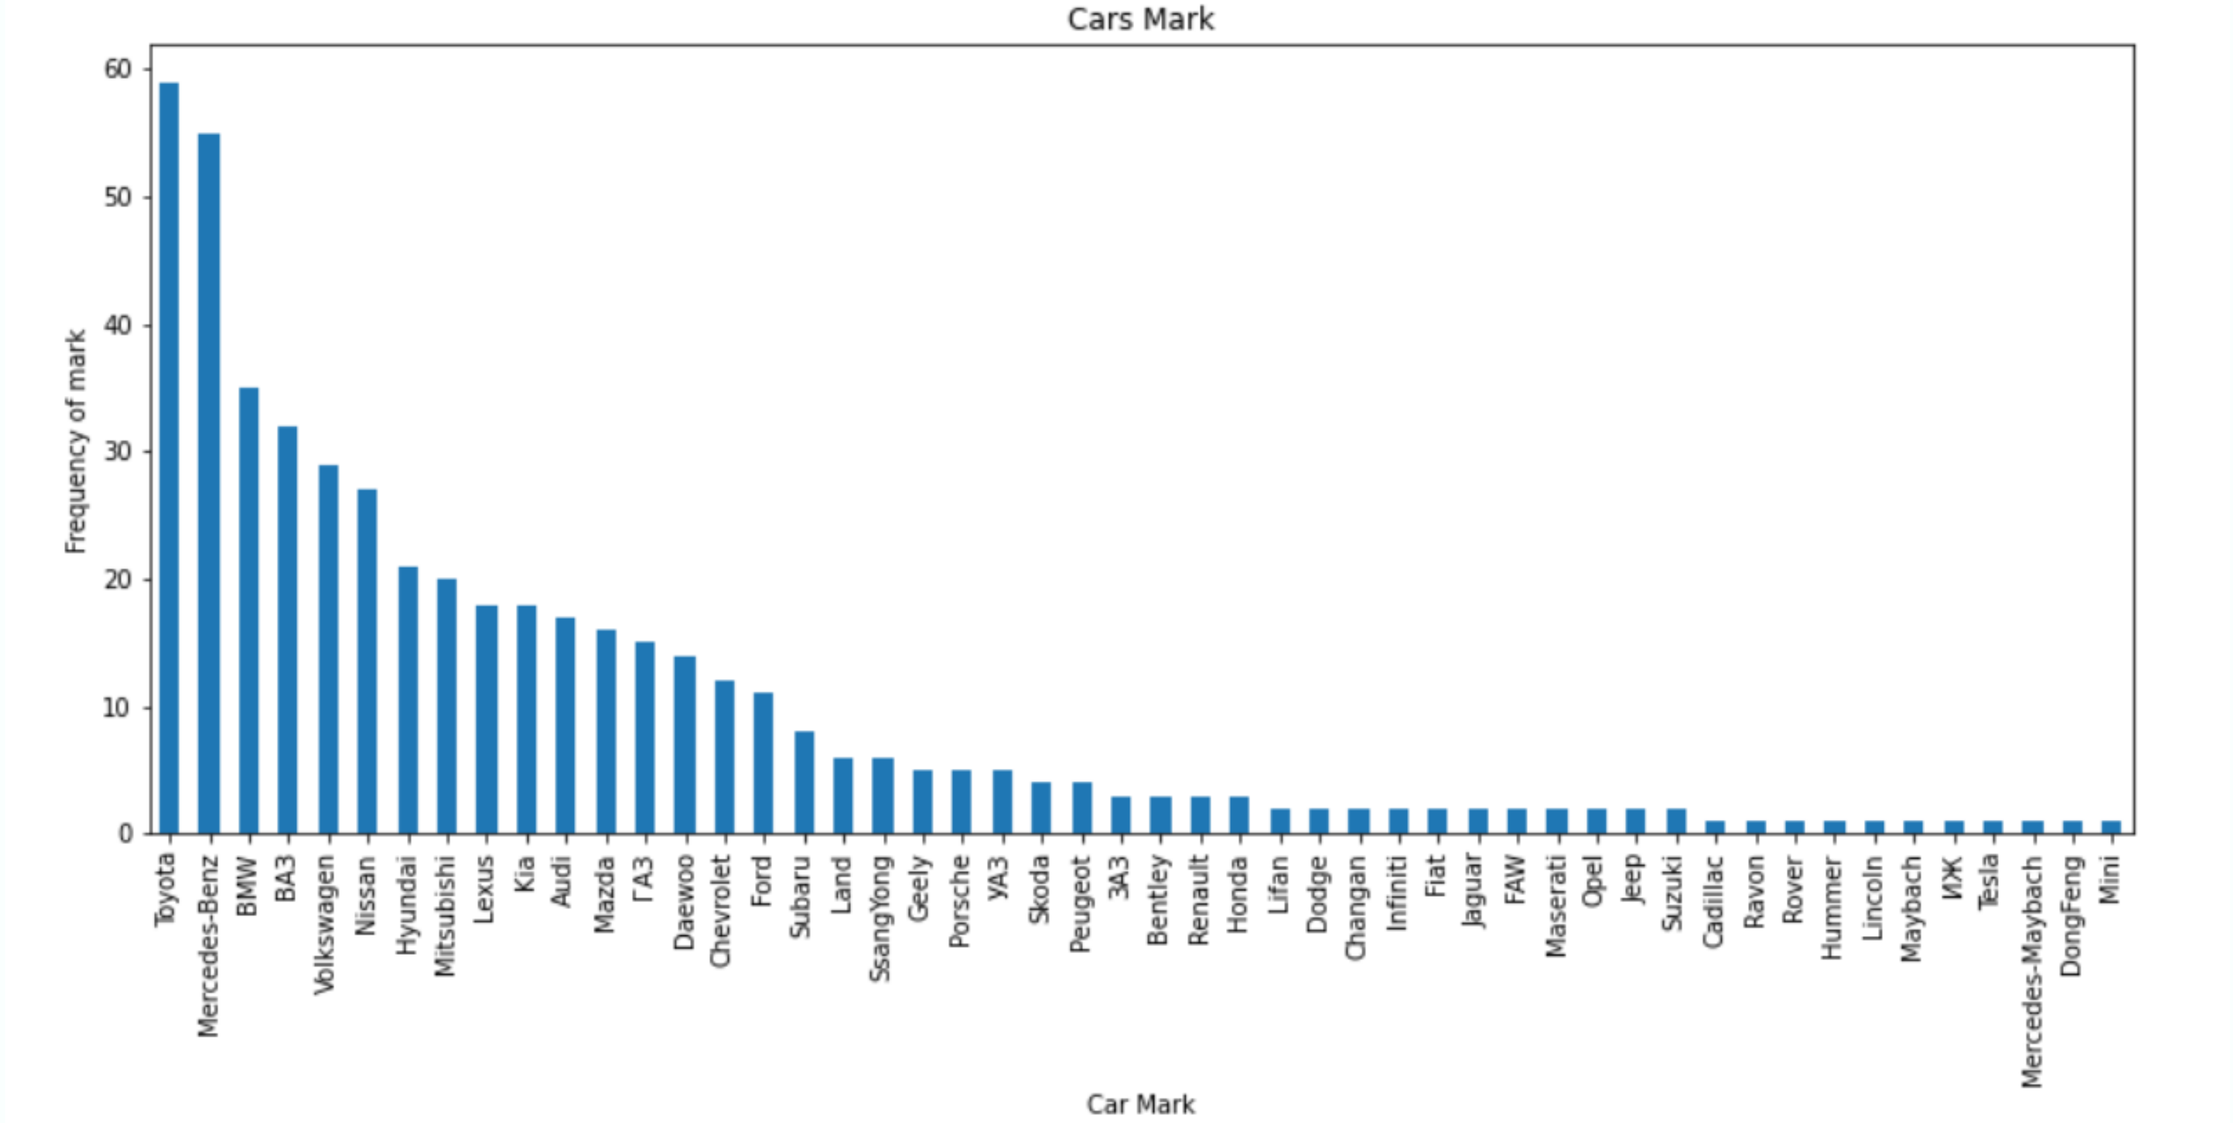

Car Mileage Spread in abnormal dataframe

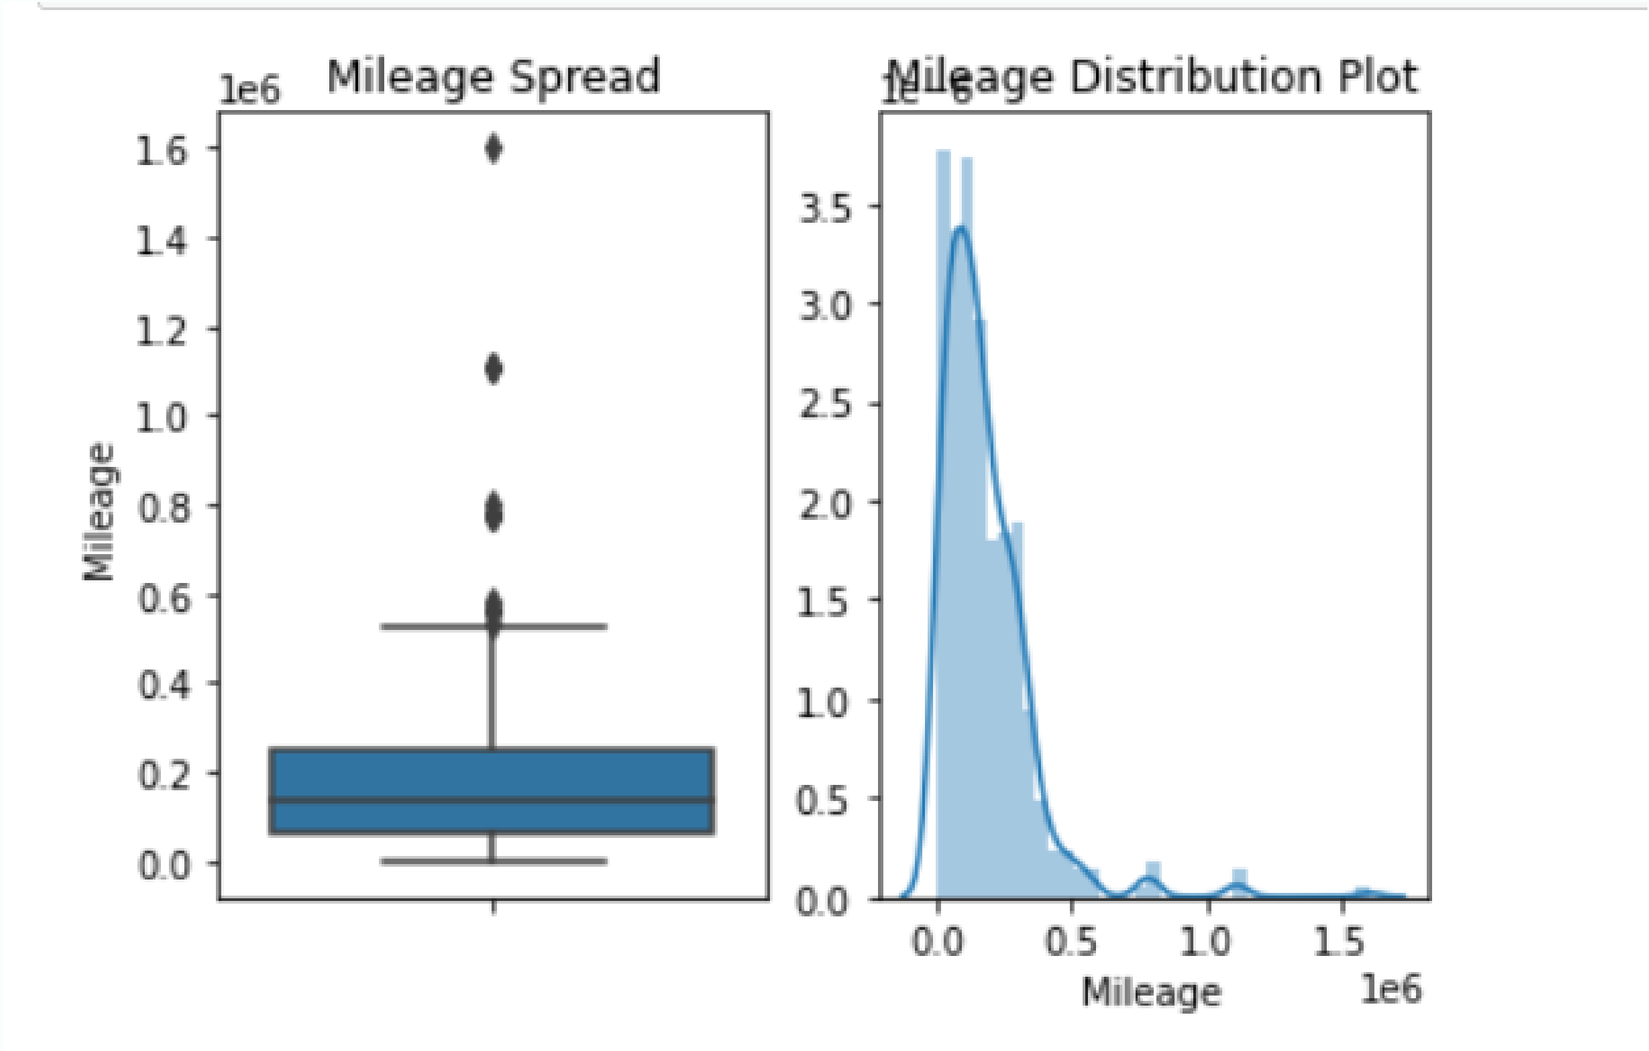

Car Fuel Type/ Car Type Histogram Spread in abnormal dataframe

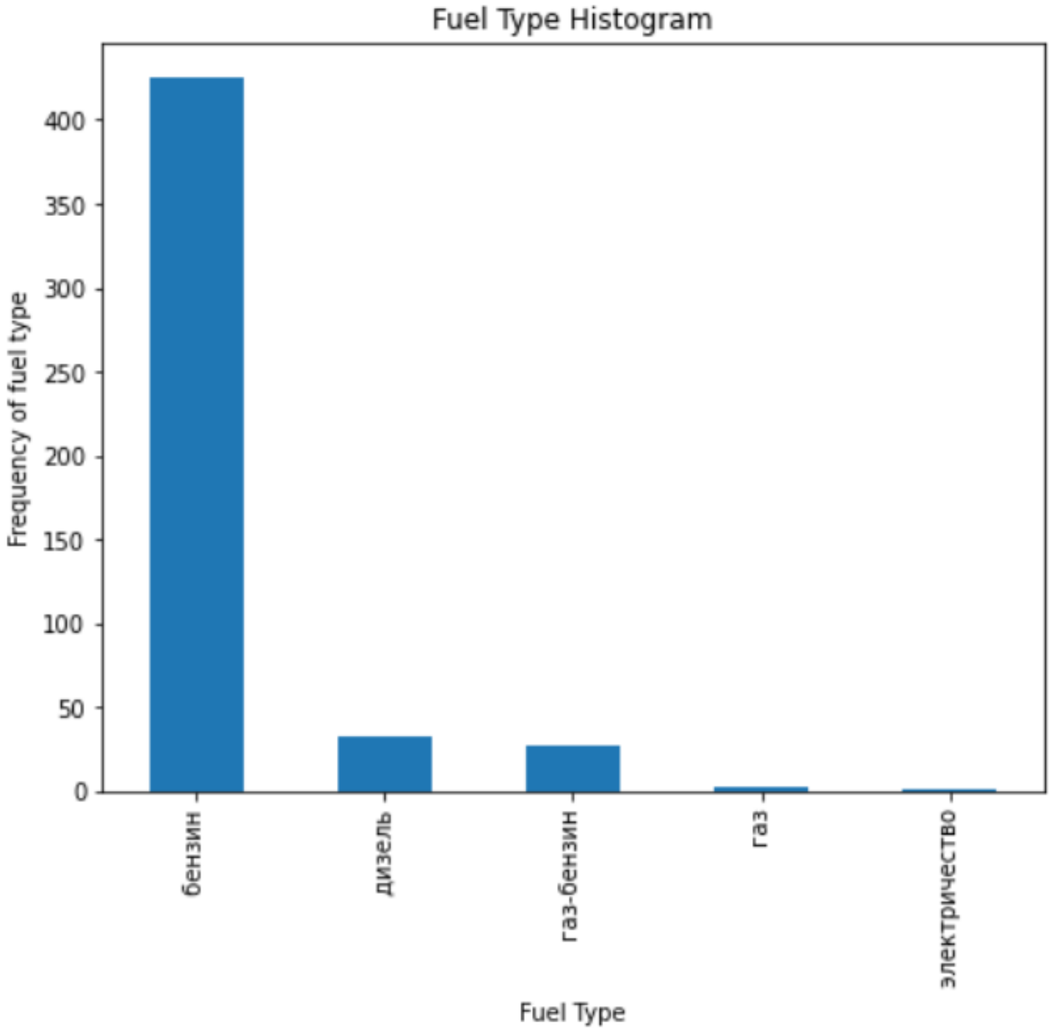

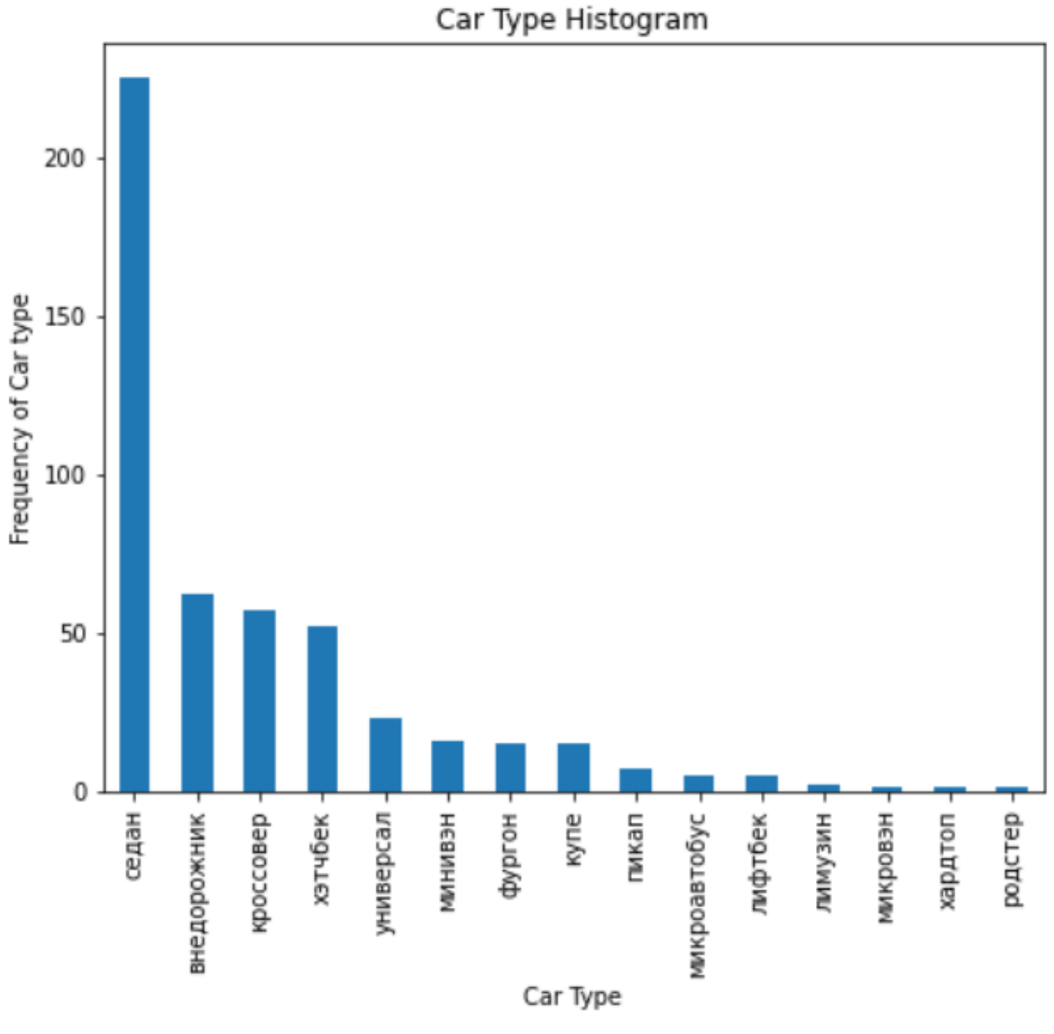

How to improve our model accuracy?

1) Use more category data

2) Add more data for prediction model

Thank you for your attention!

```
(all_cars/cars).sort_values(ascending=False).head(25).to_frame()
```

	Mark
Honda	17.000000
Toyota	8.590909
Lexus	8.000000
Renault	7.000000
Hyundai	6.529412
Kia	6.285714
Skoda	6.000000
Land	5.800000
Subaru	5.750000
Infiniti	5.500000
Nissan	4.333333
Cadillac	4.000000
Ravon	4.000000
Mercedes-Benz	3.702128
Mitsubishi	3.611111
Suzuki	3.500000
Opel	3.500000
Volkswagen	3.296296
Porsche	3.250000
BA3	3.233333
BMW	3.032258
Peugeot	2.750000
Audi	2.705882
Chevrolet	2.583333
Jeep	2.500000